TRƯỜNG ĐẠI HỌC THỦY LỢI

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP LỚN
HỌC PHẦN HỌC MÁY

ĐỀ TÀI:
DỰ ĐOÁN NGUY CƠ TRẦM CẢM Ở SINH VIÊN

Giảng viên hướng dẫn: TS. Tạ Quang Chiểu
Sinh viên: Nguyễn Thị Phương Anh
Nguyễn Minh Hiếu

Lớp: 64HTTT4

Hà Nội, 2024

LỜI NÓI ĐẦU

Sức khoẻ tinh thần đang ngày càng trở nên được quan tâm nhiều hơn, đặc biệt là về trầm cảm, bởi nó có thể gây ảnh hưởng nghiêm trọng tới chính chất lượng cuộc sống của người bệnh nói riêng và nền kinh thế, đời sống xã hội nói chung. Qua những số liệu thực tế, chúng em nhận thấy sự cần thiết trong việc ứng dụng thực tiễn và sự hữu ích đề tài này sẽ mang lại cho quá trình học tập của mình. Như vậy, chúng em đã quyết định triển khai đề tài *"Dự đoán nguy cơ trầm cảm ở sinh viên"* để dự đoán nguy cơ mắc bệnh trầm cảm ở sinh viên – một trong những đối tượng có nguy cơ trầm cảm cao nhất.

Mục tiêu chính của chúng em là áp dụng và kết hợp các thuật toán phân lớp để dự đoán các yếu tố quan trọng dẫn đến trầm cảm cũng như xây dựng mô hình có độ chính xác cao, tối ưu nhất.

Chúng em tin rằng đề tài sẽ giúp các trường học, cơ quan y tế, giáo dục có cái nhìn rõ ràng hơn về tình trạng trầm cảm ở sinh viên hiện nay, qua đó có thể phát hiện và can thiệp kịp thời.

Xin chân thành cảm ơn thầy Tạ Quang Chiểu đã tận tình hướng dẫn và hỗ trợ chúng em hoàn thành đề tài "*Dự đoán nguy cơ trầm cảm ở sinh viên*".

Chúng em xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC CÁC HÌNH ẢNH

DANH MỤC BẢNG BIỂU

CHƯƠNG 1 GIỚI THIỆU BÀI TOÁN

1.1 Đặt vấn đề

Trong những năm gần đây, cùng với sự phát triển của thời đại, tầm quan trọng của sức khoẻ tinh thần ngày càng nhận được nhiều sự quan tâm từ xã hội. Bất cứ ai, bất cứ độ tuổi hay ngành nghề nào cũng đều có khả năng trở thành nạn nhân của trầm cảm. Trầm cảm nếu không được phát hiện và có biện pháp can thiệp kịp thời sẽ dẫn đến những hậu quả ảnh hưởng tới cuộc sống của chính người bị trầm cảm như giảm năng lực học tập, làm việc, những trường hợp trầm cảm nặng còn dẫn tới xu hướng tự làm hại bản thân và thậm chí là tự sát [1]. Theo Tổ chức Y tế Thế giới (WHO), trầm cảm là nguyên nhân hàng đầu gây ra các vấn đề về sức khỏe tinh thần, ảnh hưởng đến hơn 280 triệu người trên toàn thế giới mỗi năm, trong đó sinh viên là nhóm đối tượng dễ bị tổn thương nhất [2]. Nghiên cứu từ Hiệp hội Tâm lý học Hoa Kỳ (APA) cho thấy hơn 41% sinh viên đại học tham gia báo cáo có các triệu chứng của lo âu hoặc trầm cảm [3].

Không chỉ là trên thế giới, tại Việt Nam, vấn đề sức khoẻ tinh thần ở sinh viên cũng là một vấn đề được nhiều người quan tâm. Năm 2021, Bộ Y tế và Bộ Giáo dục đã phối hợp thực hiện cuộc khảo sát trên 15.000 sinh viên từ các trường đại học cho thấy, khoảng 20-25% sinh viên có dấu hiệu của trầm cảm, lo âu hoặc căng thẳng kéo dài [4]. Những con số này minh chứng rõ ràng cho thực trạng đáng lo ngại của vấn đề sức khỏe tinh thần của sinh viên hiện nay.

Nhận thấy sự thiết thực và tính ứng dụng cho việc học tập của mình, nhóm chúng em đã quyết định triển khai đề tài *"Dự đoán nguy cơ trầm cảm ở sinh viên"* nhằm ứng dụng mô hình học máy vào quá trình dự đoán nguy cơ trầm cảm thay cho quá trình thực hiện khám bệnh thủ công tương đối khó thực hiện một cách phổ biến cho toàn bộ sinh viên trong một trường học nói riêng và phạm vi rộng hơn như cả nước nói chung. Việc tự động hóa quá trình dự đoán trầm cảm sẽ giúp cho những quy trình nghiên cứu, thống kê và khám chữa bệnh về sau được thực hiện một cách nhanh chóng hơn.

1.2 Phương pháp thực hiện

1. Thu thập dữ liệu đầu vào
2. Tiền xử lý dữ liệu
3. Lựa chọn mô hình: Thử nghiệm với các thuật toán Cây quyết định (Decision Tree), SVM (Support Vector Machine), Hồi quy logistic (Logistic Regression)
4. Huấn luyện mô hình: Huấn luyện mô hình dựa trên tập huấn luyện
5. Đánh giá mô hình: Đánh giá độ hiệu quả và kết quả của mô hình
6. Triển khai mô hình

Dữ liệu đầu vào:

Bộ dữ liệu "Student Depression" bao gồm các đặc điểm như thông tin nhân khẩu học (tuổi, giới tính), kết quả học tập (điểm, chuyên cần), thói quen lối sống (thời gian ngủ, tập thể dục, hoạt động xã hội), tiền sử sức khỏe tâm thần và phản ứng với thang đo trầm cảm tiêu chuẩn [5]. Dữ liệu gồm 27900 hàng và 18 cột.

Nguồn dữ liệu: Student Depression Dataset.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

Bài toán dự đoán nguy cơ trầm cảm ở sinh viên có mục tiêu đầu ra là nhãn Depression Yes hoặc No, với đầu vào là các yếu tố liên quan trong dữ liệu ban đầu. Như vậy, ta áp dụng một số thuật toán phân loại nhị phân để giải quyết bài toán.

2.1 Cây quyết định (Decision Tree)

ID3 (Iterative Dichotomiser 3) là một thuật toán học có giám sát (supervised learning) dùng để tạo ra cây quyết định. Nó hoạt động bằng cách chọn các thuộc tính tốt nhất để phân chia dữ liệu và xây dựng cây theo các giá trị của thuộc tính đó cho đến khi đạt được lá đại diện cho lớp của dữ liệu.

Để xét chọn các thuộc tính, ta sử dụng hàm số Entropy:

Cho một phân phối xác suất của một biến rời rạc x có thể nhận n giá trị khác nhau $x_1,x_2,\ldots,x_n$. Giả sử rằng xác suất để x nhận các giá trị này là $p_i = p\ (x = x_i)$ với $0 \leq p_i \leq 1, \sum_{i=1}^{n} pi = 1$ [6] . Ký hiệu phân phối này là $p=(p_1,p_2,\ldots,p_n)$. Entropy của phân phối này được định nghĩa là

$$H(p) = -\sum_{i=1}^{n} \text{pi} \log(\text{pi}) \qquad (2\text{-}1)$$

trong đó log là logarit tự nhiên.

Xét bài toán với *C* class khác nhau, giả sử ta đang làm việc với một *non-leaf* với các điểm dữ liệu tạo thành một tập *S* với số phần tử là $|S| = N$. Giả sử thêm rằng trong số N điểm dữ liệu này, $N_c , c = 1, 2, \ldots, C$ điểm thuộc vào class c. Xác suất để mỗi điểm dữ liệu rơi vào một class s được xấp xỉ bằng $\frac{Nc}{N}$ (maxium likehood estimation) [6]

Entropy tại

$$H(S) = -\sum_{c=1}^{C} \frac{Nc}{N} \log\left(\frac{Nc}{N}\right) \qquad (2\text{-}2)$$

Giả sử thuộc tính được chọn là x. Dựa trên x, các điểm dữ liệu trong *S* được phân ra thành *K* child note $S_1, S_2, \ldots, S_k$ với số điểm trong mỗi child node lần lượt là $m_1, m_2, \ldots, m_{k..}$ Ta định nghĩa

$$H(x, S) = \sum_{k=1}^{K} \frac{mk}{N} H(Sk) \qquad (2\text{-}3)$$

Ta định nghĩa *information gain* dựa trên thuộc tính x

$$G(x, S) = H(S) - H(x, S) \qquad (2\text{-}4)$$

Tại mỗi node, thuộc tính được chọn được xác định dựa trên

$$x^* = \text{argmax } G(x,S) = \text{argmin } H(x,S) \qquad (2\text{-}5)$$

Các bước hoạt động của thuật toán [7]:

Algorithm GenDecTree(Sample S, Attlist A)

1. Tạo một nút N
2. Nếu tất cả các mẫu thuộc cùng lớp C thì N được gán nhãn C; dừng thuật toán
3. Nếu A là rỗng thì N được gán nhãn C là nhãn phổ biến nhất trong S; dừng thuật toán;
4. Chọn a ∈ A có độ đo *information gain* cao nhất; gán nhãn N theo a;
5. Với mỗi giá trị v của a:
    a. Phát triển 1 nhánh từ N với điều kiện a = v
    b. Đặt S_v là tập con của S với a = v
    c. Nếu S_v là rỗng thì gắn một lá có nhãn phổ biến nhất trong S
    d. Ngược lại gắn một nút được tạo bởi GenDecTree(S_v, A – a)

2.2 Hồi quy logistic (Logistic regression)

Mặc dù có tên gọi là hồi quy nhưng thuật toán này lại được sử dụng trong các bài toán phân lớp không phải giá trị liên tục do nó có đầu ra dưới dạng nhị phân 0 hoặc 1. Hồi quy logistic có dạng $y = f(\boldsymbol{w^T x})$, trong đó $f(\boldsymbol{w^T x})$ là hàm kích hoạt (activation function).

Để giới hạn kết quả đầu ra, ta sử dụng hàm sigmoid:

$$f(s) = \frac{1}{1+ e^{(-s)}} \triangleq \sigma(s) \qquad (2\text{-}6)$$

Hàm này bị chặn trong khoảng (0, 1), phù hợp với yêu cầu đầu ra của thuật toán.

Hàm mất mát:

$$P(y_i \mid x_i; w) = z^{y_i}{}_i (1 - z_i)^{1-y_i} \qquad (2\text{-}7)$$

Ta cầm tìm w để hàm số P(y | X; w) trên toàn bộ training set đạt giá trị lớn nhất

$$J(w) = -\log P(y|X;w)$$

$$= \sum_{i=1}^{N} (yi \log zi + (1 - yi) \log(1 - zi)) \qquad (2\text{-}8)$$

hay

$$w = w + \eta(y_i - z_i)x_i \qquad (2\text{-}9)$$

Sau khi có w, ta dự đoán nhãn

$$\hat{y} = sigmoid(w_0 + w_1x_1 + w_2x_2 + \ldots + w_dx_d) \qquad (2\text{-}10)$$

Nếu $\hat{y} > 0.5$ thì x thuộc về lớp 1, ngược lại, x thuộc về lớp 0.

2.3 SVM (Support Vector Machine)

SVM tìm kiếm một siêu phẳng (hyperplane) để phân tách dữ liệu thuộc hai lớp khác nhau sao cho khoảng cách từ siêu phẳng này đến các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất.

Một siêu phẳng trong không gian n chiều có thể được biểu diễn dưới dạng

$$\boldsymbol{w * x + b = 0} \qquad (2\text{-}11)$$

trong đó

- ***w:*** vector trọng số
- ***x:*** vector dữ liệu
- ***b:*** bias

Khoảng cách từ một điểm đến siêu phẳng được tính bằng công thức

$$\frac{|wTx0+b|}{||w||2} \qquad (2\text{-}12)$$

Trong đó $w = [w_0, w_1, \ldots, w_d]^T$

Nếu bỏ dấu trị tuyệt đối ở tử số, ta biết được điểm đó nằm về phía nào của mặt phẳng đang xét:

- Những điểm mang dấu dương nằm về cùng 1 phía
- Những điểm mang dấu âm nằm về phía còn lại

- Những điểm nằm trên mặt phẳng làm cho tử số có giá trị bằng 0, tức khoảng cách bằng 0

Bài toán tối ưu:

$$(w, b) = argmin\ \frac{1}{2}\|w\| \qquad (2\text{-}13)$$

thoả mãn: $1 - y_n (w^T x_n + b) \leq 0, \forall\ n = 1, 2, \ldots, N$

Sau khi đã tìm được mặt phân cách $w^T x + b = 0$
Nhãn của bất kỳ một diểm được xác định bằng $class(x) = sgn(w^T x + b)$

2.4 Đánh giá kết quả mô hình

2.4.1 Tính chính xác

$$Accuracy = \frac{\text{Số phán đoán chính xác}}{\text{Tổng số phán đoán}}$$

2.4.2 Ma trận nhầm lẫn

- TP_i (true positive): Số lượng dữ liệu thuộc lớp c_i được phân loại chính xác vào lớp ci
- FP_i (false positive): Số lượng dữ liệu bên ngoài bị phân loại nhầm vào lớp c_i
- TN_i (true negative): Số lượng dữ liệu không thuộc lớp c_i được phân loại (chính xác)
- FN_i (false negative): Số lượng dữ liệu thuộc lớp c_i bị phân loại nhầm (vào các lớp khác c_i)

Bảng 2.1 Minh hoạ ma trận nhầm lẫn

Lớp c_i		Được phân loại bởi hệ thống	
		Thuộc	Không thuộc
Nhãn lớp đúng	Thuộc	TP_i	FN_i
	Không thuộc	FP_i	TN_i

2.4.3 Precision và recall

Precision đối với lớp c_i: Tổng số các ví dụ thuộc lớp c_i phân loại chính xác được chia cho tổng số các ví dụ được phân loại vào lớp c_i

$$\text{Precision}(c_i) = TP_i / (TP_i + FP_i)$$

Recall đối với lớp c_i: Tổng số các ví dụ thuộc lớpci phân loại chính xác được chia cho tổng số các ví dụ thuộc lớp c_i

$$\text{Recall}(c_i) = TP_i / (TP_i + FN_i)$$

Tiêu chí đánh giá F1 là sự kết hợp của 2 tiêu chí đánh giá Precision và Recall

$$F1 = 2*(\text{Precision} * \text{Recall})/(\text{Precision} + \text{Recall})$$

2.4.4 K-fold cross-validation

K-fold cross-validation là một phương pháp đánh giá mô hình phổ biến, chia dữ liệu thành K tập con (folds) và sử dụng K – 1 tập để huấn luyện và 1 tập để kiểm tra, lặp lại K lần. Điều này giúp đánh giá hiệu suất mô hình ổn định hơn so với việc chỉ chia dữ liệu thành một tập huấn luyện và kiểm tra duy nhất.

CHƯƠNG 3 DỮ LIỆU VÀ TIỀN XỬ LÝ DỮ LIỆU

3.1 Nguồn dữ liệu

Bộ dữ liệu "Student Depression" được lấy trên Kaggle với 27900 hàng và 18 cột, được nhiều người tin cậy và sử dụng.

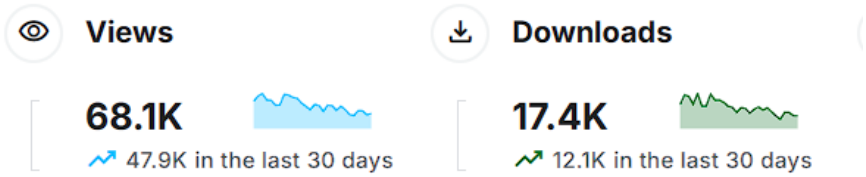

Hình 3.1 Độ tin cậy của dữ liệu

Nguồn dữ liệu: [Student Depression Dataset.]

```
main = pd.read_csv(r'/kaggle/input/student-depression-dataset/Student Depression Dataset.csv')
main
```

Hình 3.2 Code đọc dữ liệu

	id	Gender	Age	City	Profession	Academic Pressure	Work Pressure	CGPA	Study Satisfaction	Job Satisfaction	Sleep Duration	Dietary Habits	Degree	Have you ever had suicidal thoughts ?	Work/Study Hours	Financial Stress	Family History of Mental Illness	Depression
0	2	Male	33.0	Visakhapatnam	Student	5.0	0.0	8.97	2.0	0.0	5-6 hours	Healthy	B.Pharm	Yes	3.0	1.0	No	1
1	8	Female	24.0	Bangalore	Student	2.0	0.0	5.90	5.0	0.0	5-6 hours	Moderate	BSc	No	3.0	2.0	Yes	0
2	26	Male	31.0	Srinagar	Student	3.0	0.0	7.03	5.0	0.0	Less than 5 hours	Healthy	BA	No	9.0	1.0	Yes	0
3	30	Female	28.0	Varanasi	Student	3.0	0.0	5.59	2.0	0.0	7-8 hours	Moderate	BCA	Yes	4.0	5.0	Yes	1
4	32	Female	25.0	Jaipur	Student	4.0	0.0	8.13	3.0	0.0	5-6 hours	Moderate	M.Tech	Yes	1.0	1.0	No	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
27896	140685	Female	27.0	Surat	Student	5.0	0.0	5.75	5.0	0.0	5-6 hours	Unhealthy	Class 12	Yes	7.0	1.0	Yes	0
27897	140686	Male	27.0	Ludhiana	Student	2.0	0.0	9.40	3.0	0.0	Less than 5 hours	Healthy	MSc	No	0.0	3.0	Yes	0
27898	140689	Male	31.0	Faridabad	Student	3.0	0.0	6.61	4.0	0.0	5-6 hours	Unhealthy	MD	No	12.0	2.0	No	0
27899	140690	Female	18.0	Ludhiana	Student	5.0	0.0	6.88	2.0	0.0	Less than 5 hours	Healthy	Class 12	Yes	10.0	5.0	No	1
27900	140699	Male	27.0	Patna	Student	4.0	0.0	9.24	1.0	0.0	Less than 5 hours	Healthy	BCA	Yes	2.0	3.0	Yes	1

27901 rows × 18 columns

Hình 3.3 Dữ liệu ban đầu

Giải thích thuộc tính

Bảng 3.1 Bảng mô tả ý nghĩa các thuộc tính trong bộ dữ liệu

STT	Thuộc tính	Mô tả	Ý nghĩa

1	id	Định danh cho từng sinh viên thực hiện khảo sát	Được sử dụng để phân biệt từng cá nhân trong dataset
2	age	Độ tuổi của người thực hiện khảo sát, thể hiện dưới dạng số nguyên	Một số độ tuổi nhất định có nguy cơ cao hơn đối với các vấn đề tâm lý
3	gender	Giới tính (Male/Female)	Giới tính có thể ảnh hưởng đến mức độ nhạy cảm với trầm cảm
4	city	Thành phố nơi cá nhân đang sinh sống	Yếu tố địa lý có thể ảnh hưởng đến môi trường sống và áp lực
5	CGPA	Điểm trung bình tích lũy của sinh viên, ở đây được đánh giá trên thang điểm từ 0 đến 10	Hiệu suất học tập có thể liên quan đến sự căng thẳng của cá nhân
6	Sleep duration	Số giờ ngủ trung bình mỗi ngày	Giấc ngủ là yếu tố quan trọng ảnh hưởng đến sức khỏe tinh thần
7	Profession	Nghề nghiệp hiện tại của cá nhân	Nghề nghiệp liên quan đến mức độ áp lực và sức khỏe tinh thần
8	Work pressure	Mức độ áp lực trong công việc, được đánh giá trên thang từ 0 đến 5	Ảnh hưởng trực tiếp đến sức khỏe tinh thần của người lao động
9	Academic pressure	Mức độ áp lực học tập (được đánh giá trên thang từ 0 đến 5)	Là một yếu tố chính gây căng thẳng và trầm cảm, đặc biệt ở sinh viên
10	Study Satisfaction	Mức độ hài lòng với việc học (được đánh giá trên thang từ 0 đến 5)	Hài lòng với việchọc có thể giảm nguy cơ trầm cảm

11	Job Satisfaction	Mức độ hài lòng với công việc (được đánh giá trên thang từ 0 đến 5)	Sự hài lòng trong công việc ảnh hưởng lớn đến sức khỏe tinh thần
12	Dietary habit	Chế độ ăn uống của cá nhân (lành mạnh hoặc không lành mạnh).	Thói quen ăn uống ảnh hưởng đến sức khỏe cả thể chất và tinh thần
13	Degree	Trình độ học vấn hiện tại	Mức học vấn có thể liên quan đến áp lực học tập
14	Have you ever had suicidal thoughts?	Câu trả lời Có/Không về việc từng có ý định tự sát.	Là dấu hiệu cảnh báo quan trọng cho các vấn đề sức khỏe tinh thần nghiêm trọng
15	Work/Study Hours	Số giờ làm việc hoặc học tập mỗi ngày.	Làm việc hoặc học tập quá mức có thể dẫn đến căng thẳng và kiệt sức
16	Financial Stress	Mức độ căng thẳng do vấn đề tài chính (được đánh giá trên thang từ 0 đến 5)	Các vấn đề tài chính có thể là nguồn áp lực lớn
17	Family History of Mental Illness	Có hoặc không có tiền sử gia đình mắc bệnh tâm thần	Là một yếu tố nguy cơ tiềm ẩn đối với trầm cảm
18	Depression	Phân loại Yes hoặc No	Là biến mục tiêu, được sử dụng để phân tích và dự đoán

3.2 Tiền xử lý dữ liệu

Với bước tiền xử lý dữ liệu, ta thực hiện các công việc loại bỏ những giá trị nhiễu, dư thừa và biến đổi dữ liệu cho từng thuộc tính.

3.2.1 Loại bỏ nhiễu và biến đổi dữ liệu

Xét thuộc tính id, ta thực hiện loại bỏ thuộc tính này vì nó không ảnh hưởng tới kết quả đầu ra

```
main = main.drop(['id'], axis=1)
```

Hình 3.4 Code loại bỏ thuộc tính dư thừa

Thực hiện biến đổi dữ liệu của thuộc tính "*Gender*" để giúp cho việc xử lý dữ liệu dễ dàng hơn. Ta biến đổi giá trị "Male" thành 0 và "Female" thành 1

```
main.loc[main['Gender'] == 'Male', 'Gender'] = 0
main.loc[main['Gender'] == 'Female', 'Gender'] = 1
```

Hình 3.5 Code biến đổi dữ liệu

Kết quả sau xử lý

	Gender	Age	City	Profession	Academic Pressure	Work Pressure	CGPA	Study Satisfaction	Job Satisfaction	Sleep Duration	Dietary Habits	Degree	Have you ever had suicidal thoughts ?	Work/Study Hours	Financial Stress	Family History of Mental Illness	Depression
0	0	33.0	Visakhapatnam	Student	5.0	0.0	8.97	2.0	0.0	5-6 hours	Healthy	B.Pharm	Yes	3.0	1.0	No	1
1	1	24.0	Bangalore	Student	2.0	0.0	5.90	5.0	0.0	5-6 hours	Moderate	BSc	No	3.0	2.0	Yes	0
2	0	31.0	Srinagar	Student	3.0	0.0	7.03	5.0	0.0	Less than 5 hours	Healthy	BA	No	9.0	1.0	Yes	0
3	1	28.0	Varanasi	Student	3.0	0.0	5.59	2.0	0.0	7-8 hours	Moderate	BCA	Yes	4.0	5.0	Yes	1
4	1	25.0	Jaipur	Student	4.0	0.0	8.13	3.0	0.0	5-6 hours	Moderate	M.Tech	Yes	1.0	1.0	No	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
27896	1	27.0	Surat	Student	5.0	0.0	5.75	5.0	0.0	5-6 hours	Unhealthy	Class 12	Yes	7.0	1.0	Yes	0
27897	0	27.0	Ludhiana	Student	2.0	0.0	9.40	3.0	0.0	Less than 5 hours	Healthy	MSc	No	0.0	3.0	Yes	0
27898	0	31.0	Faridabad	Student	3.0	0.0	6.61	4.0	0.0	5-6 hours	Unhealthy	MD	No	12.0	2.0	No	0
27899	1	18.0	Ludhiana	Student	5.0	0.0	6.88	2.0	0.0	Less than 5 hours	Healthy	Class 12	Yes	10.0	5.0	No	1
27900	0	27.0	Patna	Student	4.0	0.0	9.24	1.0	0.0	Less than 5 hours	Healthy	BCA	Yes	2.0	3.0	Yes	1

27901 rows × 17 columns

Hình 3.6 Kết quả sau khi xử lý

Đối với thuộc tính "*City*", ta kiểm tra và đếm số giá trị trong dữ liệu

```
main['City'].value_counts()
```

Hình 3.7 Code kiểm tra dữ liệu

Kết quả thu được

City	
Kalyan	1570
Srinagar	1372
Hyderabad	1340
Vasai-Virar	1290
Lucknow	1155
Thane	1139
Ludhiana	1111
Agra	1094
Surat	1078
Kolkata	1066
Jaipur	1036
Patna	1007
Visakhapatnam	969
Pune	968
Ahmedabad	951
Bhopal	934
Chennai	885
Meerut	825
Rajkot	816
Delhi	768
Bangalore	767
Ghaziabad	745
Mumbai	699
Vadodara	694
Varanasi	685
Nagpur	651
Indore	643
Kanpur	609
Nashik	547
Faridabad	461
Saanvi	2
Bhavna	2
City	2
Harsha	2
Kibara	1
Nandini	1
Nalini	1
Mihir	1
Nalyan	1
M.Com	1
ME	1
Rashi	1
Gaurav	1
Reyansh	1
Harsh	1
Vaanya	1
Mira	1
Less than 5 Kalyan	1
3.0	1
Less Delhi	1
M.Tech	1
Khaziabad	1

Hình 3.8 Kết quả thu được

Để tăng độ phổ biến và chính xác cho mô hình, ta loại bỏ những thành phố có số lượng thu được dưới 400

```
cities_to_remove = main['City'].value_counts()[main['City'].value_counts() < 400]
main = main[~main['City'].isin(cities_to_remove.index)]
main['City'].value_counts()
```

Hình 3.9 Code xử lý nhiễu

Kết quả thu được

City	
Kalyan	1570
Srinagar	1372
Hyderabad	1340
Vasai-Virar	1290
Lucknow	1155
Thane	1139
Ludhiana	1111
Agra	1094
Surat	1078
Kolkata	1066
Jaipur	1036
Patna	1007
Visakhapatnam	969
Pune	968
Ahmedabad	951
Bhopal	934
Chennai	885
Meerut	825
Rajkot	816
Delhi	768
Bangalore	767
Ghaziabad	745
Mumbai	699
Vadodara	694
Varanasi	685
Nagpur	651
Indore	643
Kanpur	609
Nashik	547
Faridabad	461

Hình 3.10 Kết quả thu được

Đối với thuộc tính "*Profession*", ta thực hiện kiểm tra dữ liệu ban đầu

```
main['Profession'].value_counts()
```

Hình 3.11 Code kiểm tra dữ liệu

Kết quả thu được

Profession	
Student	27844
Architect	8
Teacher	6
Digital Marketer	3
Content Writer	2
Chef	2
Doctor	2
Pharmacist	2
Civil Engineer	1
UX/UI Designer	1
Educational Consultant	1
Manager	1
Lawyer	1
Entrepreneur	1

Hình 3.12 Kết quả thu được

Có thể thấy rằng dữ liệu chứa cả những ngành nghề không phải sinh viên (đối tượng chính đề tài muốn hướng dến), ta lọc những dữ liệu mang giá trị "Student":

```
main = main.loc[main['Profession'] == 'Student']
main['Profession'].value_counts()
```

```
Profession
Student    27844
```

Hình 3.13 *Code kiểm tra và kết quả*

Tuy nhiên, nếu một cột dữ liệu chỉ mang một giá trị thì nó không có ý nghĩa trong việc xây dựng mô hình, ta thực hiện loại bỏ thuộc tính "*Profession"*

```
main = main.drop(['Profession'], axis=1)
```

Hình 3.14 *Code thực hiện*

Ta tiếp tục xét đến thuộc tính "*Work pressure*", vì đã lọc bỏ những ngành nghề khác ngoài sinh viên nên giá trị của thuộc tính này gần như 100% là 0, ta thực hiện loại bỏ thuộc tính vì nó không cần thiết

```
main['Work Pressure'].value_counts()
```

```
Work Pressure
0.0    27841
5.0        2
2.0        1
```

Hình 3.15 Kiểm tra dữ liệu

Thực hiện loại bỏ thuộc tính "*Work pressure"*

```
main = main.drop(['Work Pressure'], axis=1)
```

Hình 3.16 *Code thực hiện*

	Gender	Age	City	Academic Pressure	CGPA	Study Satisfaction	Job Satisfaction	Sleep Duration	Dietary Habits	Degree	Have you ever had suicidal thoughts ?	Work/Study Hours	Financial Stress	Family History of Mental Illness	Depression
0	0	33.0	Visakhapatnam	5.0	8.97	2.0	0.0	5-6 hours	Healthy	B.Pharm	Yes	3.0	1.0	No	1
1	1	24.0	Bangalore	2.0	5.90	5.0	0.0	5-6 hours	Moderate	BSc	No	3.0	2.0	Yes	0
2	0	31.0	Srinagar	3.0	7.03	5.0	0.0	Less than 5 hours	Healthy	BA	No	9.0	1.0	Yes	0
3	1	28.0	Varanasi	3.0	5.59	2.0	0.0	7-8 hours	Moderate	BCA	Yes	4.0	5.0	Yes	1
4	1	25.0	Jaipur	4.0	8.13	3.0	0.0	5-6 hours	Moderate	M.Tech	Yes	1.0	1.0	No	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
27896	1	27.0	Surat	5.0	5.75	5.0	0.0	5-6 hours	Unhealthy	Class 12	Yes	7.0	1.0	Yes	0
27897	0	27.0	Ludhiana	2.0	9.40	3.0	0.0	Less than 5 hours	Healthy	MSc	No	0.0	3.0	Yes	0
27898	0	31.0	Faridabad	3.0	6.61	4.0	0.0	5-6 hours	Unhealthy	MD	No	12.0	2.0	No	0
27899	1	18.0	Ludhiana	5.0	6.88	2.0	0.0	Less than 5 hours	Healthy	Class 12	Yes	10.0	5.0	No	1
27900	0	27.0	Patna	4.0	9.24	1.0	0.0	Less than 5 hours	Healthy	BCA	Yes	2.0	3.0	Yes	1

27844 rows × 15 columns

Hình 3.17 Kết quả sau khi thực hiện

Thực hiện kiểm tra dữ liệu với thuộc tính "*Age*", ta thu được kết quả:

Age			
24.0	2255	35.0	10
20.0	2235	38.0	8
28.0	2128	36.0	7
29.0	1940	42.0	4
33.0	1892	48.0	3
25.0	1780	39.0	3
21.0	1718	43.0	2
23.0	1640	46.0	2
18.0	1586	37.0	2
19.0	1560	49.0	1
34.0	1466	51.0	1
27.0	1459	44.0	1
31.0	1422	59.0	1
32.0	1258	54.0	1
22.0	1159	58.0	1
26.0	1153	56.0	1
30.0	1144	41.0	1

Hình 3.18 Kết quả thu được

Loại bỏ những dữ liệu có độ tuổi lớn hơn 30 do những giá trị còn lại có số lượng dữ liệu rất ít và có thể gây nhiễu cho quá trình chạy mô hình

```
main = main.loc[main['Age'] <= 30]
```

Hình 3.19 Code thực hiện

Age	
24.0	2255
20.0	2235
28.0	2128
29.0	1940
25.0	1780
21.0	1718
23.0	1640
18.0	1586
19.0	1560
27.0	1459
22.0	1159
26.0	1153
30.0	1144

Hình 3.20 Kết quả sau khi thực hiện

Kiểm tra thuộc tính "*Academic pressure*", ta thu được

```
Academic Pressure
3.0    5785
5.0    5167
4.0    4112
1.0    3546
2.0    3140
0.0       7
```

Hình 3.21 Số giá trị của thuộc tính

Thực hiện lược bỏ dữ liệu mang giá trị 0 (vì số lượng của giá trị này quá ít) bằng cách giữ lại những giá trị lớn hơn 0

```
main = main.loc[main['Academic Pressure'] > 0]
```

Hình 3.22 Xử lý nhiễu

Tiếp tục kiểm tra thuộc tính "Study Satisfaction"

```
Study Satisfaction
4.0    4825
2.0    4686
3.0    4448
1.0    4336
5.0    3453
0.0       2
```

Hình 3.23 Kết quả kiểm tra

Loại bỏ giá trị nhiễu

```
main = main.loc[main['Study Satisfaction'] > 0]
```

Hình 3.24 Code xử lý

Thực hiện loại bỏ cột "*Job Satisfaction*" do đã loại bỏ cột "*Work pressure*"

```
main = main.drop(['Job Satisfaction'], axis=1)
```

Hình 3.25 Code xử lý

Thực hiện kiểm tra dữ liệu "*Sleep Duration*", nhận thấy rằng giá trị "Other" có thể gây nhiễu, ta thực hiện lược bỏ chúng

```
Sleep Duration
Less than 5 hours    6515
7-8 hours            5732
5-6 hours            4787
More than 8 hours    4702
Others                 12
```

Hình 3.26 Số lượng các giá trị trong thuộc tính

Thực hiện và kiểm tra kết quả

```
main = main.loc[main['Sleep Duration'] != 'Others']
main['Sleep Duration'].value_counts()
```

Hình 3.27 Code xử lý

```
Sleep Duration
Less than 5 hours    6515
7-8 hours            5732
5-6 hours            4787
More than 8 hours    4702
```

Hình 3.28 Kết quả thu được

Thực hiện biến đổi các giá trị trên thành giá trị dạng số để đơn giản hoá dữ liệu

```
main.loc[main['Sleep Duration'] == 'Less than 5 hours', 'Sleep Duration'] = 0
main.loc[main['Sleep Duration'] == '5-6 hours', 'Sleep Duration'] = 1
main.loc[main['Sleep Duration'] == '7-8 hours', 'Sleep Duration'] = 2
main.loc[main['Sleep Duration'] == 'More than 8 hours', 'Sleep Duration'] = 3
```

Hình 3.29 Code biến đổi dữ liệu

```
Sleep Duration
0    6515
2    5732
1    4787
3    4702
```

Hình 3.30 Kết quả

Xét thuộc tính "*Dietary Habits*", ta loại bỏ thuộc tính gây nhiễu và thực hiện biến đổi dữ liệu sang dạng số

```
Dietary Habits
Unhealthy    8361
Moderate     7594
Healthy      5784
Others          9
```

Hình 3.31 Dữ liệu ban đầu

```
main = main.loc[main['Dietary Habits'] != 'Others']

main.loc[main['Dietary Habits'] == 'Healthy', 'Dietary Habits'] = 0
main.loc[main['Dietary Habits'] == 'Unhealthy', 'Dietary Habits'] = 1
main.loc[main['Dietary Habits'] == 'Moderate', 'Dietary Habits'] = 2
```

Hình 3.32 Code xử lý

```
Dietary Habits
1    8361
2    7594
0    5784
```

Hình 3.33 Kết quả thu được

Kiểm tra giá trị của thuộc tính "*Degree*"

```
main['Degree'].unique()
```

ta thu được

```
array(['BSc', 'BCA', 'M.Tech', 'PhD', 'Class 12', 'B.Ed', 'M.Ed', 'MSc',
       'BHM', 'M.Pharm', 'MCA', 'MA', 'B.Pharm', 'B.Com', 'MD', 'BE',
       'BA', 'MBBS', 'B.Arch', 'LLM', 'B.Tech', 'BBA', 'M.Com', 'ME',
       'MBA', 'LLB', 'Others', 'MHM'], dtype=object)
```

Hình 3.34 Kết quả thu được

Để thuận tiện cho việc xử lý dữ liệu về sau, ta tạo một thuộc tính mới "*New_Degree*", dữ liệu trong thuộc tính mới sẽ được tổng hợp từ thuộc tính "*Degree*".

Giá trị của mới "*New_Degree*" gồm có "Graduated", "Post Graduated" và "Higher Secondary".

Đồng thời, ta loại bỏ giá trị "Other" của cột "*Degree*".

```
main.loc[main['Degree'].str.contains(r'BSc|BCA|B.Ed|BHM|B.Pharm|B.Com|BE|BA|B.Arch|B.Tech|BBA|LLB', regex=True), 'New_Degree'] = 'Graduated'
main.loc[main['Degree'].str.contains(r'MSc|MCA|M.Ed|M.Pharm|M.Com|ME|MA|M.Arch|M.Tech|MBA|LLM', regex=True), 'New_Degree'] = 'Post Graduated'
main.loc[main['Degree'] == 'Class 12', 'New_Degree'] = 'Higher Secondary'
main = main.loc[main['Degree'] != 'Others']
```

Hình 3.35 Code xử lý

Thuộc tính mới:

```
New_Degree
Graduated           9790
Higher Secondary    5839
Post Graduated      4873
```

Hình 3.36 Thuộc tính mới

Thực hiện biến đổi giá trị trên thành dạng số để dễ dàng xử lý

```
main.loc[main['New_Degree'] == 'Graduated', 'New_Degree'] = 0
main.loc[main['New_Degree'] == 'Post Graduated', 'New_Degree'] = 1
main.loc[main['New_Degree'] == 'Higher Secondary', 'New_Degree'] = 2
```

Hình 3.37 Code biến đổi dữ liệu

	New_Degree
0	9790
2	5839
1	4873

Hình 3.38 Kết quả thu được

Xét thuộc tính "*Have you ever had suicidal thought?*", ta biến đổi giá trị trong thuộc tính này thành dạng số

```
main.loc[main['Have you ever had suicidal thoughts ?'] == 'Yes', 'Have you ever had suicidal thoughts ?'] = 1
main.loc[main['Have you ever had suicidal thoughts ?'] == 'No', 'Have you ever had suicidal thoughts ?'] = 0
```

Hình 3.39 Code biến đổi dữ liệu

	Have you ever had suicidal thoughts ?
1	14275
0	7436

Hình 3.40 Kết quả thu được

Xét thuộc tính *"Work/Study Hours"* và *"Financial Stress"* không có giá trị nào gây nhiễu.

Với thuộc tính "", ta biến đổi dữ liệu thành dạng số

```
main.loc[main['Family History of Mental Illness'] == 'Yes', 'Family History of Mental Illness'] = 1
main.loc[main['Family History of Mental Illness'] == 'No', 'Family History of Mental Illness'] = 0
```

Hình 3.41 Code biến đổi dữ liệu

	Family History of Mental Illness
0	11196
1	10515

Hình 3.42 Kết quả thu được

Sau khi đã xem xét tất cả các thuộc tính, ta kiểm tra xem trong dữ liệu có dữ liệu nào bị thiếu (mang giá trị null) hay không và loại bỏ chúng

```
main.isnull().sum()
main = main.dropna()
```

Hình 3.43 Code thực hiện

Thực hiện xoá bỏ cột "*City*" và "*Degree*" không còn cần thiết

```
main = main.drop(['City'], axis=1)

main = main.drop(['Degree'], axis=1)
```

Hình 3.44 Code thực hiện

Dữ liệu thu được

	Gender	Age	Academic Pressure	CGPA	Study Satisfaction	Sleep Duration	Dietary Habits	Have you ever had suicidal thoughts ?	Work/Study Hours	Financial Stress	Family History of Mental Illness	Depression	New_Degree
1	1	24.0	2.0	5.90	5.0	1	2	0	3.0	2.0	1	0	0
3	1	28.0	3.0	5.59	2.0	2	2	1	4.0	5.0	1	1	0
4	1	25.0	4.0	8.13	3.0	1	2	1	1.0	1.0	0	0	1
6	0	30.0	3.0	9.54	4.0	2	0	0	1.0	2.0	0	0	0
7	1	30.0	2.0	8.04	4.0	0	1	0	0.0	1.0	1	0	2
...	...	...	...	...	...	...	...	...	...	...	...	...	...
27893	1	24.0	3.0	6.02	2.0	2	2	0	8.0	2.0	0	0	0
27896	1	27.0	5.0	5.75	5.0	1	1	1	7.0	1.0	1	0	2
27897	0	27.0	2.0	9.40	3.0	0	0	0	0.0	3.0	1	0	1
27899	1	18.0	5.0	6.88	2.0	0	0	1	10.0	5.0	0	1	2
27900	0	27.0	4.0	9.24	1.0	0	0	1	2.0	3.0	1	1	0

20501 rows × 13 columns

Hình 3.45 Dữ liệu sau khi xử lý

3.2.2 Ma trận tương quan

```
plt.figure(figsize=(20, 10))
sns.heatmap(main_data.corr(), annot=True, cmap='coolwarm')
plt.show()
```

Hình 3.46 Code thực hiện

Ta sử dụng ma trận tương quan dưới dạng heatmap nhằm xác định mối quan hệ giữa các thuộc tính trong dữ liệu

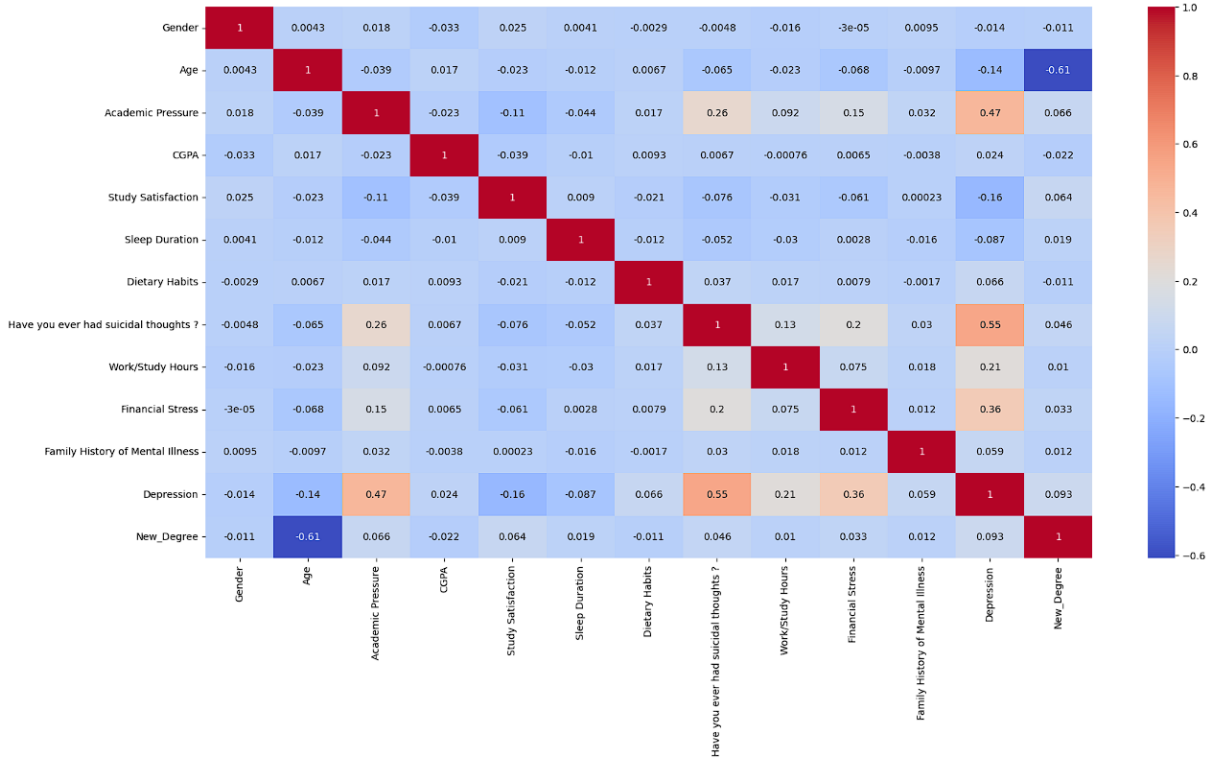

Hình 3.47 Kết quả thu được

Ở biểu đồ này, mối quan hệ giữa các thuộc tính có màu càng nóng (hướng về màu đỏ) thì các thuộc tính đó có xu hướng biến đổi cùng chiều với nhau, ngược lại, chúng sẽ biến đổi ngược chiều với màu càng lạnh (màu xanh).

Như vậy, ta có thể thấy các thuộc tính "*Academic pressure", "Have you ever had suicidal thought?"* và *"Finacial stress"* có mức độ tương quan với thuộc tính mục tiêu "*Depression*" hơn các thuộc tính khác.

3.2.3 Dữ liệu đưa vào thực hiện

Dữ liệu sau khi tiền xử lý gồm 20501 hàng và 13 cột, gồm có các thuộc tính: *'Gender', 'Age'', 'Academic Pressure', 'CGPA', 'Study Satisfaction', 'Sleep Duration', 'Dietary Habits', 'Degree', 'Have you ever had suicidal thoughts ?', 'Work/Study Hours', 'Financial Stress', 'Family History of Mental Illness', 'Depression', 'New_Degree'*

	Gender	Age	Academic Pressure	CGPA	Study Satisfaction	Sleep Duration	Dietary Habits	Have you ever had suicidal thoughts ?	Work/Study Hours	Financial Stress	Family History of Mental Illness	Depression	New_Degree
1	1	24.0	2.0	5.90	5.0	1	2	0	3.0	2.0	1	0	0
3	1	28.0	3.0	5.59	2.0	2	2	1	4.0	5.0	1	1	0
4	1	25.0	4.0	8.13	3.0	1	2	1	1.0	1.0	0	0	1
6	0	30.0	3.0	9.54	4.0	2	0	0	1.0	2.0	0	0	0
7	1	30.0	2.0	8.04	4.0	0	1	0	0.0	1.0	1	0	2
...	...	...	...	...	...	...	...	...	...	...	...	...	...
27893	1	24.0	3.0	6.02	2.0	2	2	0	8.0	2.0	0	0	0
27896	1	27.0	5.0	5.75	5.0	1	1	1	7.0	1.0	1	0	2
27897	0	27.0	2.0	9.40	3.0	0	0	0	0.0	3.0	1	0	1
27899	1	18.0	5.0	6.88	2.0	0	0	1	10.0	5.0	0	1	2
27900	0	27.0	4.0	9.24	1.0	0	0	1	2.0	3.0	1	1	0

20501 rows × 13 columns

Hình 3.48 Dữ liệu được đưa vào sử dụng

CHƯƠNG 4 THỰC HIỆN VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Sử dụng thuật toán Hồi quy tuyến tính và đánh giá kết quả

4.1.1 Thực hiện

Đầu tiên, ta loại bỏ giá trị trong thuộc tính "*Depression*" do đây là thuộc tính mục tiêu

```
X = main_encoded.drop('Depression', axis=1).values
y = main_encoded['Depression'].values
```

Hình 4.1 Code xác định biến mục tiêu

Chia dữ liệu thành tập huấn luyện và tập kiểm tra, tập kiểm tra sẽ chiếm 20% dữ liệu đưa vào ban đầu

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Hình 4.2 Code chia training set và test set

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Hình 4.3 Code khởi tạo

StandardScaler(): Tạo một đối tượng StandardScaler. Phương pháp này chuẩn hóa dữ liệu sao cho mỗi đặc trưng có trung bình bằng 0 và độ lệch chuẩn bằng 1.

scaler.fit_transform(X_train): Tính toán các tham số chuẩn hóa (trung bình và độ lệch chuẩn) từ tập huấn luyện X_train và áp dụng chuẩn hóa cho dữ liệu huấn luyện.

scaler.transform(X_test): Áp dụng cùng các tham số chuẩn hóa (được tính từ X_train) lên dữ liệu kiểm tra X_test.

Ta sử dụng thuật toán Hồi quy tuyến tính với dữ liệu huấn luyện

```
model = LogisticRegression()
model.fit(X_train_scaled, y_train)
```

Hình 4.4 Đưa vào dữ liệu huấn luyện

Đưa ra độ chính xác

```
score = model.score(X_test_scaled, y_test)
print(f"Accuracy: {score*100:.2f}%")
```

```
Accuracy: 85.29%
```

Hình 4.5 Đánh giá độ chính xác

4.1.2 Đánh giá kết quả

Ta có thể thấy độ chính xác khá cao khi ứng dụng Hồi quy tuyến tính với dữ liệu này đạt 85.29%.

Tiếp theo, ta xét ma trận nhầm lẫn (confusion matrix)

```
y_pred = model.predict(X_test_scaled)
cm = confusion_matrix(y_test, y_pred)

plt.figure(figsize=(6, 4))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', xticklabels=['Predicted: 0', 'Predicted: 1'], yticklabels=['Real: 0', 'Real: 1'])
plt.title('Confusion Matrix')
plt.xlabel('Predicted Values')
plt.ylabel('Real Values')
plt.show()
```

Hình 4.6 Code biểu diễn ma trận nhầm lẫn

Kết quả thu được

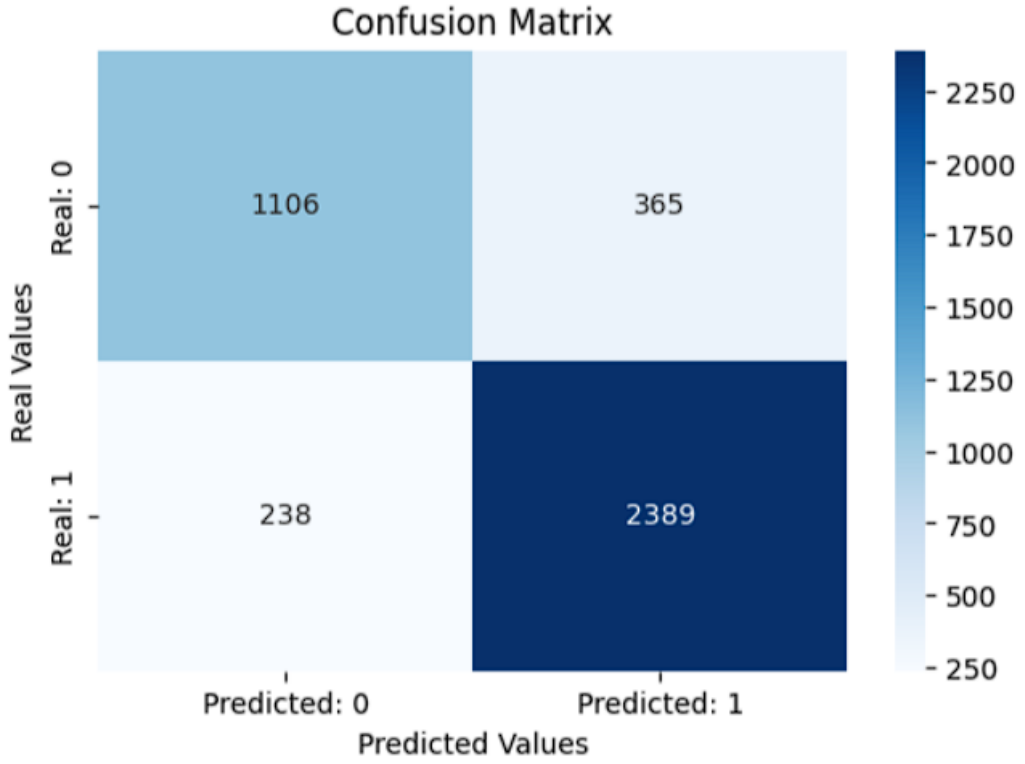

Hình 4.7 Ma trận nhầm lẫn

Dựa vào ma trận nhầm lẫn trong hình, ta có thể thấy rằng:

- True Positives (TP): Số trường hợp dự đoán đúng là lớp 1 (thực tế là 1 và dự đoán là 1). Trong ma trận, đây là ô chứa giá trị 2389.
- True Negatives (TN): Số trường hợp dự đoán đúng là lớp 0 (thực tế là 0 và dự đoán là 0). Trong ma trận, đây là ô chứa giá trị 1106.
- False Positives (FP): Số trường hợp dự đoán là lớp 1 nhưng thực tế là lớp 0 (thực tế là 0 nhưng dự đoán là 1). Trong ma trận, đây là ô chứa giá trị 365.

- False Negatives (FN): Số trường hợp dự đoán là lớp 0 nhưng thực tế là lớp 1 (thực tế là 1 nhưng dự đoán là 0). Trong ma trận, đây là ô chứa giá trị 238.

Thực hiện tính toán các độ đo đánh giá, ta có:

Accuracy (Độ chính xác) = (TP + TN)/(TP + TN + FP + FN)

= (2389 + 1106)/(2389 + 1106 + 365 + 238)

= 0.8529 (85.29%)

Đây là tỷ lệ phần trăm các dự đoán đúng (cả True Positives và True Negatives) so với tổng số dự đoán. Độ chính xác khá cao, cho thấy mô hình có khả năng phân loại tốt hầu hết các trường hợp.

Precision (Độ chính xác) = TP/(TP + FP)

= 2389/(2389 + 365)

= 0.8675 (86.75%)

Độ chính xác cho lớp 1 cho biết tỷ lệ phần trăm các dự đoán lớp 1 là đúng. Với giá trị cao như vậy, mô hình ít có khả năng đưa ra dự đoán sai về lớp 1 (ít False Positives).

Recall (Độ hồi tưởng) = TP/(TP + FN)

= 2389/(2389 + 238)

= 0.9094 (90.94%)

Độ hồi tưởng cho lớp 1 cho biết tỷ lệ phần trăm các trường hợp thực tế là lớp 1 mà mô hình dự đoán đúng. Giá trị cao của recall cho thấy mô hình nhận diện tốt các trường hợp thực sự là lớp 1, nhưng vẫn còn một số ít bị bỏ sót (False Negatives).

F1-Score = 2 * (Precision * Recall)/(Precision + Recall)

= 2 * (0.8675 * 0.9094)/(0.8675 + 0.9094)

= 0.8879 (88.79%)

Đây là chỉ số kết hợp giữa precision và recall, thể hiện sự cân bằng giữa hai chỉ số này. Với F1-Score cao, mô hình đạt hiệu quả tốt trong việc cân bằng giữa độ chính xác và độ hồi tưởng.

Mô hình này hoạt động khá tốt, với các chỉ số đều trên 85%. Điều này cho thấy mô hình không chỉ chính xác mà còn nhất quán trong việc phân loại hai lớp.

Tuy nhiên, có một số trường hợp mà mô hình dự đoán sai (365 False Positives và 238 False Negatives), nhưng so với tổng số dữ liệu, tỷ lệ này khá thấp.

4.2 So sánh với các mô hình khác

Để cải thiện độ chính xác cho bài toán, ta thực hiện đánh giá với các thuật toán Cây quyết định (Decision Tree) và SVM (Support Vector Machine) bằng cách sử dụng thư viện sklearn trong Python

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
import xgboost as xgb
import lightgbm as lgb
from sklearn.metrics import accuracy_score

models = {
    "Logistic Regression": LogisticRegression(),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(random_state=42),
}
```

Hình 4.8 Code gọi mô hình

4.2.1 So sánh độ chính xác giữa các mô hình

Tính toán độ chính xác và lưu trữ kết quả

```
accuracy_results = {}

for name, model in models.items():
    model.fit(X_train_scaled, y_train)
    y_pred = model.predict(X_test_scaled)
    accuracy = accuracy_score(y_test, y_pred)
    accuracy_results[name] = accuracy
```

Hình 4.9 Tính toán và lưu trữ kết quả

Sắp xếp kết độ chính xác theo thứ tự giảm dần và biểu diễn dưới dạng biểu đồ

```
accuracy_results_ordened = dict(sorted(accuracy_results.items(), key=lambda item: item[1], reverse=True))

plt.figure(figsize=(15, 6))
sns.barplot(x=list(accuracy_results_ordened.values()),
            y=list(accuracy_results_ordened.keys()),
            palette='viridis')
plt.xlabel('Accuracy')
plt.title('Model Accuracy')

for i, v in enumerate(accuracy_results_ordened.values()):
    plt.text(v, i, f'{v*100:.2f}%', color='black', va='center')
plt.show()
```

Hình 4.10 Sắp xếp và biểu diễn dưới dạng biểu đồ

Kết quả thu được

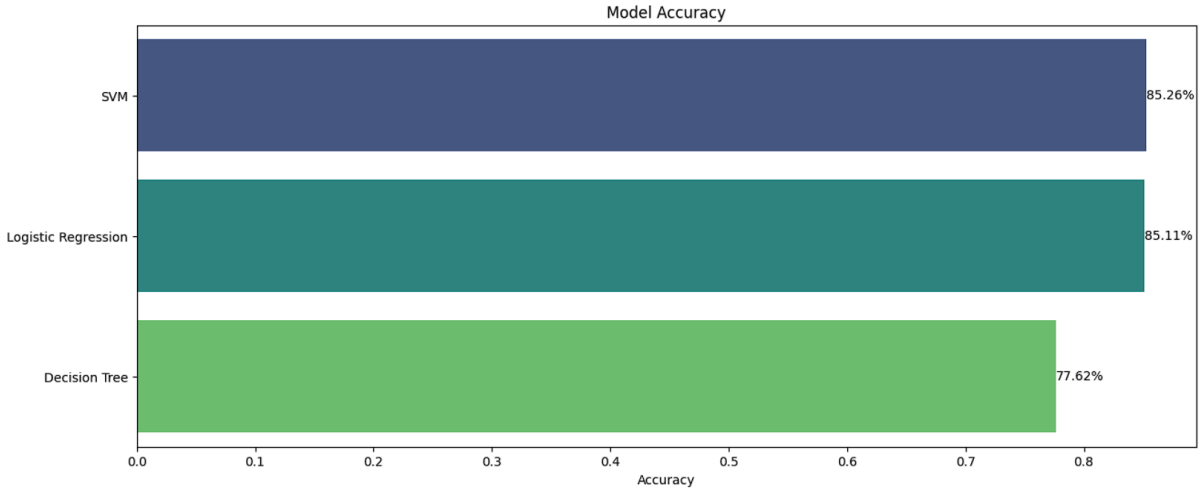

Hình 4.11 Biểu đồ thể hiện độ chính xác

Như vậy, ta có thể thấy SVM đang cho kết quả có độ chính xác cao nhất, Hồi quy logistic cho độ chính xác tương đương và Cây quyết định có độ chính xác thấp nhất.

4.2.2 Sử dụng k-fold crossvalidation

Sử dụng thư viện sklearn để tính toán và matplotib, seaborn để vẽ biểu đồ

```
from sklearn.model_selection import KFold, cross_val_score
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import make_scorer, accuracy_score
import numpy as np
import matplotlib.pyplot as plt
```

Hình 4.12 Sử dụng thư viện

Khởi tạo k-fold với k=5

```
kfold = KFold(n_splits=5, shuffle=True, random_state=42)
```

Hình 4.13 Khởi tạo k-fold

Lưu kết quả accuracy và thực hiện vòng lặp đánh giá tập huấn luyện (training set)

```
results = {name: [] for name in models.keys()}
training_sizes = np.linspace(0.1, 0.9, 9)

# Vòng lặp với từng tỷ lệ dữ liệu huấn luyện
for size in training_sizes:
    # Chọn tập dữ liệu nhỏ hơn theo tỷ lệ
    X_partial, _, y_partial, _ = train_test_split(X_scaled, y, train_size=size, random_state=42)

    # Thực hiện K-Fold với từng mô hình
    for name, model in models.items():
        # cross_val_score thực hiện huấn luyện và đánh giá trên từng fold
        scores = cross_val_score(model, X_partial, y_partial, cv=kf, scoring=make_scorer(accuracy_score
        results[name].append(scores.mean())  # Lấy trung bình của các fold
```

Hình 4.14 Code thực hiện

Biểu diễn bằng biểu đồ

```
plt.figure(figsize=(10, 6))
for name, accuracies in results.items():
    plt.plot(training_sizes, accuracies, marker='o', label=name)

# Tùy chỉnh biểu đồ
plt.title("Model Performance vs Training Size with K-Fold", fontsize=14)
plt.xlabel("Training Size (Fraction of Training Data)", fontsize=12)
plt.ylabel("Mean Accuracy (K-Fold)", fontsize=12)
plt.xticks(training_sizes, labels=[f"{int(size*100)}%" for size in training_sizes], rotation=45)
plt.ylim(0.5, 1.0)  # Giới hạn trục tung từ 50% đến 100%
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()
```

Hình 4.15 Code thực hiện

Kết quả thu được

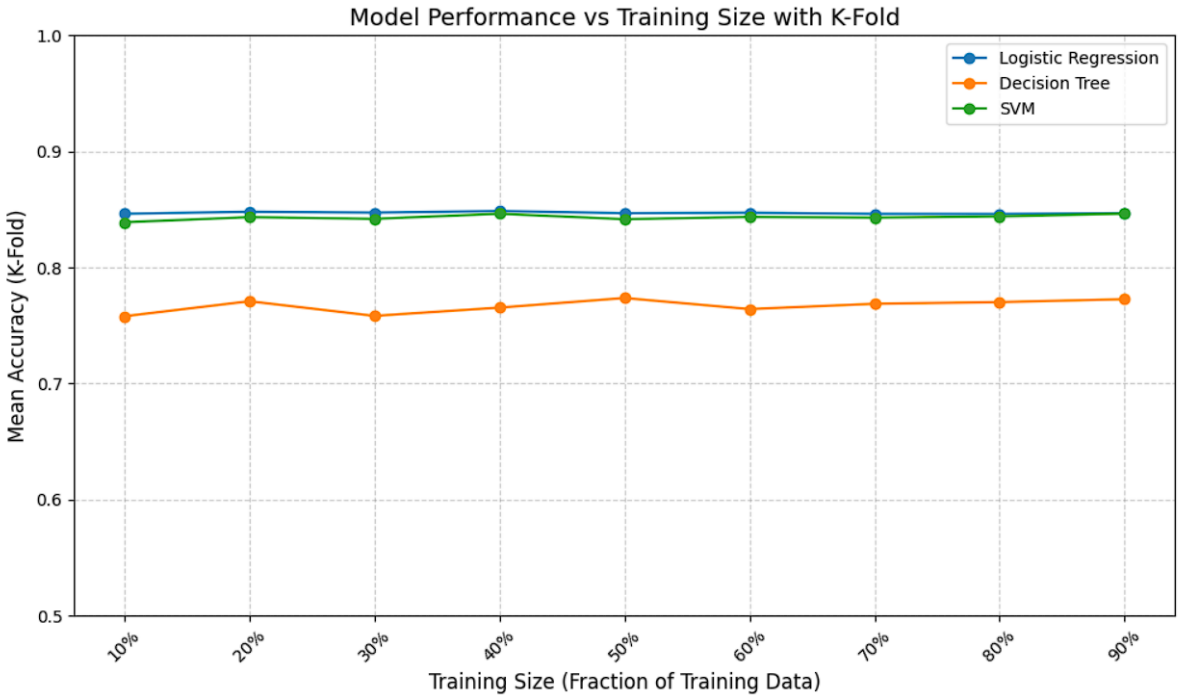

Hình 4.16 Kết quả thu được

Ta có thể thấy được hiệu suất giữa các mô hình:

- Hồi quy logistic (Logistic Regression): Có độ chính xác ổn định và cao nhất trong tất cả các tỷ lệ dữ liệu. Điều này cho thấy bài toán có thể được giải quyết hiệu quả bằng mô hình tuyến tính và hồi quy logistic là một lựa chọn phù hợp.
- Cây quyết định (Decision Tree): Độ chính xác ở mức trung bình, thấp hơn Logistic Regression. Mô hình Cây quyết định (Decision Tree) có thể đã bị overfitting trên các tập dữ liệu nhỏ (với tỷ lệ kích thước tập huấn luyện thấp) do đặc tính dễ phân nhánh quá mức.
- SVM: Hiệu suất tốt trên các tập dữ liệu nhỏ nhưng có thể không cao bằng Logistic Regression trên tập dữ liệu lớn. Điều này có thể do việc lựa chọn kernel chưa tối ưu hoặc SVM cần tinh chỉnh thêm siêu tham số để phù hợp hơn.

Dựa vào biểu đồ có thể thấy hồi quy logistic có xu hướng tăng đều và đạt hiệu suất cao nhất, Cây quyết định và SVM có sự dao động ở một vài mức dữ liệu nhỏ, nhưng dần ổn định khi dữ liệu lớn hơn.

Như vậy, ta sử dụng thuật toán hồi quy logistic (Logistic regression) xây dựng mô hình để giải quyết bài toán ban đầu.

CHƯƠNG 5 TRIỂN KHAI MÔ HÌNH

Ta triển khai mô hình với thông tin đầu vào được nhập bởi người dùng

Sử dụng các thư viện pandas, numpy và sklearn để tính toán

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, classification_report
```

Hình 5.1 Sử dụng thư viện

Xây dựng mô hình

```
# Assuming X_train is a pandas DataFrame, you can get column names from it
column_names = ['Gender', 'Age', 'Academic Pressure',
                'CGPA', 'Study Satisfaction',
                'Sleep Duration', 'Dietary Habits', 'New_Degree',
                'Have you ever had suicidal thoughts ?', 'Work/Study Hours',
                'Financial Stress', 'Family History of Mental Illness']

X_train = np.random.rand(100, 12)
y_train = np.random.randint(0, 2, size=100)

# Training logistic regression model
logistic_model = LogisticRegression(max_iter=1000)
logistic_model.fit(X_train, y_train)
```

Hình 5.2 Xây dựng mô hình

Hàm trả về kết quả dự đoán

```
def predict_depression(user_input):
    """
    Predicts depression risk based on user input.

    Parameters:
        user_input (dict): Dictionary containing user-provided information.

    Returns:
        str: Prediction result ('HAS SIGN OF DEPRESSION' or 'HAS NO SIGN OF DEPRESSION').
    """
    # Convert user input into a DataFrame
    input_df = pd.DataFrame([user_input])

    # Ensure input_df has the same structure as X_train by reindexing with column names
    input_df = input_df.reindex(columns=column_names, fill_value=0)

    # Make prediction
    prediction = logistic_model.predict(input_df)[0]

    return 'HAS SIGN OF DEPRESSION' if prediction == 1 else 'HAS NO SIGN OF DEPRESSION'
```

Hình 5.3 Hàm chạy mô hình

```
example_input = {
    'Gender': int(input("Gender (0 for Male, 1 for Female): ")),
    'Age': int(input("Age (18-30): ")),
    'Academic Pressure': int(input("Academic Pressure (0-5): ")),
    'CGPA': float(input("CGPA (0-10): ")),
    'Study Satisfaction': int(input("Study Satisfaction (0-5): ")),
    'Sleep Duration': int(input("Sleep Duration (0 for less than 5 hours, 1 for 5-6 hours, 2 for 7-8 hours, 3 for more than 8 hours): ")),
    'Dietary Habits': int(input("Dietary Habits (0 for healthy, 1 for unhealthy, 2 for moderate): ")),
    'New_Degree': int(input("Degree (0 for Graduated, 1 for Post Graduated, 2 for Higher Secondary): ")),
    'Have you ever had suicidal thoughts ?': int(input("Suicidal Thoughts (0 for No, 1 for Yes): ")),
    'Work/Study Hours': int(input("Work/Study Hours per day: ")),
    'Financial Stress': int(input("Financial Stress (0-5): ")),
    'Family History of Mental Illness': int(input("Family History of Mental Illness (0 for No, 1 for Yes): "))
}
```

Hình 5.4 Code nhập thông tin

Gọi hàm trả về kết quả

```
result = predict_depression(example_input)
print(f">>>RESULT: {result}")
```

Hình 5.5 Gọi hàm

Kiểm tra mô hình:

```
Gender (0 for Male, 1 for Female):  0
Age (18-30):  28
Academic Pressure (0-5):  4
CGPA (0-10):  7
Study Satisfaction (0-5):  2
Sleep Duration (0 for less than 5 hours, 1 for 5-6 hours, 2 for 7-8 hours, 3 for more than 8 hours):  0
Dietary Habits (0 for healthy, 1 for unhealthy, 2 for moderate):  1
Degree (0 for Graduated, 1 for Post Graduated, 2 for Higher Secondary):  1
Have you ever had suicidal thoughts ? (0 for No, 1 for Yes):  0
Work/Study Hours per day:  7
Financial Stress (0-5):  5
Family History of Mental Illness (0 for No, 1 for Yes):  1
>>>RESULT: HAS SIGN OF DEPRESSION
```

Hình 5.6 Chạy thử mô hình

```
Gender (0 for Male, 1 for Female):  1
Age (18-30):  20
Academic Pressure (0-5):  4
CGPA (0-10):  9
Study Satisfaction (0-5):  3
Sleep Duration (0 for less than 5 hours, 1 for 5-6 hours, 2 for 7-8 hours, 3 for more than 8 hours):  2
Dietary Habits (0 for healthy, 1 for unhealthy, 2 for moderate):  2
Degree (0 for Graduated, 1 for Post Graduated, 2 for Higher Secondary):  0
Have you ever had suicidal thoughts ? (0 for No, 1 for Yes):  1
Work/Study Hours per day:  9
Financial Stress (0-5):  3
Family History of Mental Illness (0 for No, 1 for Yes):  1
>>>RESULT: HAS NO SIGN OF DEPRESSION
```

Hình 5.7 Chạy thử mô hình

```
Gender (0 for Male, 1 for Female):  1
Age (18-30):  29
Academic Pressure (0-5):  5
CGPA (0-10):  6
Study Satisfaction (0-5):  2
Sleep Duration (0 for less than 5 hours, 1 for 5-6 hours, 2 for 7-8 hours, 3 for more than 8 hours):  0
Dietary Habits (0 for healthy, 1 for unhealthy, 2 for moderate):  0
Degree (0 for Graduated, 1 for Post Graduated, 2 for Higher Secondary):  1
Have you ever had suicidal thoughts ? (0 for No, 1 for Yes):  1
Work/Study Hours per day:  9
Financial Stress (0-5):  4
Family History of Mental Illness (0 for No, 1 for Yes):  0
>>>RESULT: HAS SIGN OF DEPRESSION
```

Hình 5.8 Chạy thử mô hình

TỔNG KẾT

Sau khi hoàn thành đề tài này, chúng em đã nắm bắt được những kiến thức quan trọng về các thuật toán trong phạm vi môn học học máy, đặc biệt là các thuật toán hồi quy logistic (Logistic regression), cây quyết định (Decision tree), SVM (support vector machine) cũng như cách đánh giá độ chính xác của mô hình.

Ngoài ra, chúng em cũng học được cách làm việc nhóm hiệu quả, phân chia công việc hợp lý, và phối hợp để đạt được mục tiêu chung. Những kinh nghiệm từ đề tài này không chỉ giúp chúng em nắm bắt lý thuyết mà còn mang lại kỹ năng quan trọng để áp dụng cho những bài toán thực tế cũng như những đề tài, công việc trong tương lai.

TÀI LIỆU THAM KHẢO

[1] Tổ chức Y tế Thế giới (WHO), "Depression," 2012.

[2] Tổ chức Y tế Thế giới (WHO), "Depression," 2023. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/depression.

[3] Hiệp hội Tâm lý học Hoa Kỳ (APA), "Stress in America: Stress and Mental Health," 2021. [Online]. Available: https://www.apa.org/news/press/releases/stress.

[4] "Báo cáo về sức khỏe tâm lý sinh viên trong môi trường học đường," Tạp chí Y tế công cộng Việt Nam, 2021.

[5] "Student Depression," Kaggle Competition, [Online]. Available: https://www.kaggle.com/datasets/hopesb/student-depression-dataset/data.

[6] Vũ Hữu Tiệp, "Machine Learning cơ bản," 2017. [Online]. Available: https://machinelearningcoban.com/.

[7] Tạ Quang Chiểu, Slide bài giảng Học máy, Đại học Thuỷ Lợi.

PHỤ LỤC

```
##khai báo thư viện
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import OneHotEncoder
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import confusion_matrix
import warnings
warnings.filterwarnings('ignore', category=FutureWarning)

##đọc dữ liệu
main = pd.read_csv(r'Student Depression Dataset.csv')

##tiền xử lý dữ liệu
main = main.drop(['id'], axis=1)

main.loc[main['Gender'] == 'Male', 'Gender'] = 0
main.loc[main['Gender'] == 'Female', 'Gender'] = 1

main = main.loc[main['Profession'] == 'Student']
main = main.drop(['Profession'], axis=1)

main = main.drop(['Work Pressure'], axis=1)

main = main.loc[main['Age'] <= 30]
main = main.loc[main['Academic Pressure'] > 0]

main = main.loc[main['Study Satisfaction'] > 0]

main = main.drop(['Job Satisfaction'], axis=1)

main = main.loc[main['Sleep Duration'] != 'Others']
main.loc[main['Sleep Duration'] == 'Less than 5 hours', 'Sleep Duration'] = 0
main.loc[main['Sleep Duration'] == '5-6 hours', 'Sleep Duration'] = 1
main.loc[main['Sleep Duration'] == '7-8 hours', 'Sleep Duration'] = 2
main.loc[main['Sleep Duration'] == 'More than 8 hours', 'Sleep Duration'] = 3

main = main.loc[main['Dietary Habits'] != 'Others']
main.loc[main['Dietary Habits'] == 'Healthy', 'Dietary Habits'] = 0
main.loc[main['Dietary Habits'] == 'Unhealthy', 'Dietary Habits'] = 1
main.loc[main['Dietary Habits'] == 'Moderate', 'Dietary Habits'] = 2

main.loc[main['Degree'].str.contains(r'BSc|BCA|B.Ed|BHM|B.Pharm|B.Com|BE|BA|B.
Arch|B.Tech|BBA|LLB', regex=True), 'New_Degree'] = 'Graduated'
```

```
main.loc[main['Degree'].str.contains(r'MSc|MCA|M.Ed|M.Pharm|M.Com|ME|MA|M.Arch
|M.Tech|MBA|LLM', regex=True), 'New_Degree'] = 'Post Graduated'
main.loc[main['Degree'] == 'Class 12', 'New_Degree'] = 'Higher Secondary'
main = main.loc[main['Degree'] != 'Others']

main.loc[main['New_Degree'] == 'Graduated', 'New_Degree'] = 0
main.loc[main['New_Degree'] == 'Post Graduated', 'New_Degree'] = 1
main.loc[main['New_Degree'] == 'Higher Secondary', 'New_Degree'] = 2

main.loc[main['Have you ever had suicidal thoughts ?'] == 'Yes', 'Have you
ever had suicidal thoughts ?'] = 1
main.loc[main['Have you ever had suicidal thoughts ?'] == 'No', 'Have you ever
had suicidal thoughts ?'] = 0

main.loc[main['Family History of Mental Illness'] == 'Yes', 'Family History of
Mental Illness'] = 1
main.loc[main['Family History of Mental Illness'] == 'No', 'Family History of
Mental Illness'] = 0

main = main.drop(['City'], axis=1)

main = main.drop(['Degree'], axis=1)
main.isnull().sum()
main = main.dropna()

##ma trận tương quan
plt.figure(figsize=(20, 10))
sns.heatmap(main_data.corr(), annot=True, cmap='coolwarm')
plt.show()

##xây dựng mô hình
X = main_data.drop('Depression', axis=1).values
y = main_data['Depression'].values

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

model = LogisticRegression()
model.fit(X_train_scaled, y_train)

score = model.score(X_test_scaled, y_test)
print(f"Accuracy: {score*100:.2f}%")

##ma trận nhầm lẫn
y_pred = model.predict(X_test_scaled)
```

```
cm = confusion_matrix(y_test, y_pred)

plt.figure(figsize=(6, 4))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', xticklabels=['Predicted:
0', 'Predicted: 1'], yticklabels=['Real: 0', 'Real: 1'])
plt.title('Confusion Matrix')
plt.xlabel('Predicted Values')
plt.ylabel('Real Values')
plt.show()

##so sánh các mô hình
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
import xgboost as xgb
import lightgbm as lgb
from sklearn.metrics import accuracy_score

models = {
    "Logistic Regression": LogisticRegression(),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(random_state=42),
}

accuracy_results = {}

for name, model in models.items():
    model.fit(X_train_scaled, y_train)
    y_pred = model.predict(X_test_scaled)
    accuracy = accuracy_score(y_test, y_pred)
    accuracy_results[name] = accuracy

accuracy_results_ordened = dict(sorted(accuracy_results.items(), key=lambda
item: item[1], reverse=True))

plt.figure(figsize=(15, 6))
sns.barplot(x=list(accuracy_results_ordened.values()),
            y=list(accuracy_results_ordened.keys()),
            palette='viridis')
plt.xlabel('Accuracy')
plt.title('Model Accuracy')

for i, v in enumerate(accuracy_results_ordened.values()):
    plt.text(v, i, f'{v*100:.2f}%', color='black', va='center')
plt.show()

##k-fold
from sklearn.model_selection import KFold, cross_val_score
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
```

```
from sklearn.svm import SVC
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import make_scorer, accuracy_score
import numpy as np
import matplotlib.pyplot as plt

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

models = {
    "Logistic Regression": LogisticRegression(random_state=42),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(random_state=42)
}

kf = KFold(n_splits=5, shuffle=True, random_state=42)

results = {name: [] for name in models.keys()}
training_sizes = np.linspace(0.1, 0.9, 9)

for size in training_sizes:
    X_partial, _, y_partial, _ = train_test_split(X_scaled, y,
train_size=size, random_state=42)

    for name, model in models.items():
        scores = cross_val_score(model, X_partial, y_partial, cv=kf,
scoring=make_scorer(accuracy_score))
        results[name].append(scores.mean())

# Vẽ biểu đồ
plt.figure(figsize=(10, 6))
for name, accuracies in results.items():
    plt.plot(training_sizes, accuracies, marker='o', label=name)

plt.title("Model Performance vs Training Size with K-Fold", fontsize=14)
plt.xlabel("Training Size (Fraction of Training Data)", fontsize=12)
plt.ylabel("Mean Accuracy (K-Fold)", fontsize=12)
plt.xticks(training_sizes, labels=[f"{int(size*100)}%" for size in
training_sizes], rotation=45)
plt.ylim(0.5, 1.0)  # Giới hạn trục tung từ 50% đến 100%
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)

plt.tight_layout()
plt.show()

##triển khai mô hình
import pandas as pd
import numpy as np
```

```
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, classification_report

column_names = ['Gender', 'Age', 'Academic Pressure',
                'CGPA', 'Study Satisfaction',
                'Sleep Duration', 'Dietary Habits', 'New_Degree',
                'Have you ever had suicidal thoughts ?', 'Work/Study Hours',
                'Financial Stress', 'Family History of Mental Illness']

X_train = np.random.rand(100, 12)
y_train = np.random.randint(0, 2, size=100)

logistic_model = LogisticRegression(max_iter=1000)
logistic_model.fit(X_train, y_train)

def predict_depression(user_input):
    """
    Predicts depression risk based on user input.

    Parameters:
        user_input (dict): Dictionary containing user-provided information.

    Returns:
        str: Prediction result ('HAS SIGN OF DEPRESSION' or 'HAS NO SIGN OF
DEPRESSION').
    """
    input_df = pd.DataFrame([user_input])

    input_df = input_df.reindex(columns=column_names, fill_value=0)

    prediction = logistic_model.predict(input_df)[0]

    return 'HAS SIGN OF DEPRESSION' if prediction == 1 else 'HAS NO SIGN OF
DEPRESSION'

example_input = {
    'Gender': int(input("Gender (0 for Male, 1 for Female): ")),
    'Age': int(input("Age (18-30): ")),
    'Academic Pressure': int(input("Academic Pressure (0-5): ")),
    'CGPA': float(input("CGPA (0-10): ")),
    'Study Satisfaction': int(input("Study Satisfaction (0-5): ")),
    'Sleep Duration': int(input("Sleep Duration (0 for less than 5 hours, 1
for 5-6 hours, 2 for 7-8 hours, 3 for more than 8 hours): ")),
    'Dietary Habits': int(input("Dietary Habits (0 for healthy, 1 for
unhealthy, 2 for moderate): ")),
    'New_Degree': int(input("Degree (0 for Graduated, 1 for Post Graduated, 2
for Higher Secondary): ")),
```

```
    'Have you ever had suicidal thoughts ?': int(input("Have you ever had
suicidal thoughts ? (0 for No, 1 for Yes): ")),
    'Work/Study Hours': int(input("Work/Study Hours per day: ")),
    'Financial Stress': int(input("Financial Stress (0-5): ")),
    'Family History of Mental Illness': int(input("Family History of Mental
Illness (0 for No, 1 for Yes): "))
}

result = predict_depression(example_input)
print(f">>>RESULT: {result}")
```